Análise de Sobrevivência de Empresas Brasileiras: Quanto Tempo Dura um CNPJ e Como Antecipar Baixa em 12 Meses

Diego Henrique Xavier

2026

Resumo

Este artigo apresenta um estudo aplicado sobre longevidade empresarial e risco de baixa a partir dos Dados Abertos do CNPJ. O projeto foi estruturado como um pipeline auditável em oito fases, da consolidação do dado bruto até a produção de artefatos finais, com duas perguntas centrais: quanto tempo empresas brasileiras permanecem ativas e quais sinais cadastrais ajudam a antecipar baixa em 12 meses. A camada de sobrevivência foi estimada sobre 67.175.202 empresas e 31.342.895 eventos observados, com mediana Kaplan–Meier de 14,17 anos. A camada preditiva foi construída com split temporal absoluto, foco explícito em controle de leakage e seleção final por qualidade probabilística. O modelo escolhido, `logistic_full` calibrado por isotonic, atingiu ROC-AUC de 0,6975, PR-AUC de 0,1327, Brier de 0,0594 e lift de 2,53x no top 10% do teste. O principal resultado do trabalho é menos um algoritmo isolado e mais um desenho metodológico defensável para transformar cadastro administrativo massivo em inferência temporal e score operacional.

Palavras-chave: sobrevivência empresarial; CNPJ; Kaplan–Meier; Cox; competing risks; calibração; modelagem preditiva.

1 Introdução

Medir a duração observada de empresas e antecipar sinais de baixa é um problema relevante para monitoramento econômico, produtos analíticos de risco e inteligência de mercado. Em bases administrativas massivas, porém, a maior dificuldade não está apenas no modelo final. Ela começa na definição da unidade analítica, no tratamento do tempo, no controle de leakage e na distinção entre leitura estrutural e previsão operacional.

Este projeto foi desenhado para responder duas perguntas complementares:

1. quanto tempo duram empresas brasileiras quando observadas a partir do cadastro aberto do CNPJ;
2. quais sinais cadastrais ajudam a antecipar baixa no horizonte de 12 meses sem violar coerência temporal.

O estudo usa como fonte principal o leiaute oficial da base CNPJ disponibilizado pela Receita Federal [Receita Federal do Brasil, 2018]. A solução não busca explicação causal da mortalidade empresarial. O objetivo é produzir uma leitura temporal auditável da base e um radar probabilístico útil como score operacional.

2 Dados e Desenho do Estudo

2.1 Fonte e unidade analítica

Os Dados Abertos do CNPJ incluem informações como número de inscrição, situação cadastral, data da situação cadastral, data de abertura, natureza jurídica e CNAE principal [Receita Federal do Brasil, 2018]. No projeto, a unidade analítica foi ancorada em `cnpj_basico`, aproximando a empresa pela matriz para manter coerência entre origem, evento e janelas temporais.

O evento principal de sobrevivência foi definido como baixa observada por `situacao_cadastral = 08`. A origem temporal foi `data_inicio_atividade` e a censura administrativa foi fixada em 2026-03-15. Essa escolha permite interpretar o problema como tempo até baixa ou censura sob uma fotografia cadastral massiva.

2.2 Estrutura do pipeline

O trabalho foi organizado em oito fases: diagnóstico e integridade, preprocessamento, auditoria temporal, análise exploratória, sobrevivência, modelagem do radar 12M, storytelling e artefatos finais. Essa separação importa porque a maior parte do ganho metodológico veio do encadeamento entre consistência de base, recorte temporal e avaliação, e não de otimização agressiva de algoritmo.

2.3 Desenho temporal do radar

O radar de baixa em 12 meses foi formulado como classificação probabilística com split temporal absoluto:

- treino em 2022;
- validação em 2023;
- teste em 2024.

As features foram mantidas deliberadamente enxutas e temporalmente defensáveis. Colunas de fotografia direta do futuro foram removidas na auditoria, e a seleção final do modelo priorizou calibração e estabilidade, além de discriminação.

3 Metodologia

3.1 Sobrevivência

As curvas de sobrevivência foram estimadas com Kaplan–Meier [Kaplan and Meier, 1958]. Como camada explicativa adicional, o projeto incluiu um Cox proporcional de riscos em caráter exploratório [Cox, 1972]. Essa etapa foi tratada como leitura associativa, não causal, justamente porque a base cadastral representa uma fotografia observada e não um histórico longitudinal perfeito de todas as covariáveis.

3.2 Competing risks

Além da sobrevivência global, foi produzida uma leitura por motivos de baixa com uma ótica de competing risks. O objetivo não foi estimar causalidade por motivo, mas decompor a incidência

acumulada observada das principais causas administrativas, em linha com a literatura de riscos competitivos [Fine and Gray, 1999].

3.3 Radar 12M

Na camada preditiva, diferentes famílias de modelos foram comparadas em validação temporal. A regra final de escolha considerou empate prático em PR-AUC e desempate por qualidade probabilística, especialmente Brier score [Brier, 1950], log-loss e simplicidade operacional. A versão escolhida foi `logistic_full` com calibração isotonic.

4 Resultados

4.1 Panorama geral de sobrevivência

A base final de sobrevivência contém 67.175.202 empresas e 31.342.895 eventos observados de baixa, o que corresponde a uma taxa observada de evento de 46,66%. A mediana Kaplan–Meier foi de 14,17 anos.

Tabela 1: Probabilidades de sobrevivência estimadas no conjunto geral

Horizonte	Sobrevivência estimada
1 ano	85,43%
3 anos	75,74%
5 anos	68,62%
10 anos	57,18%

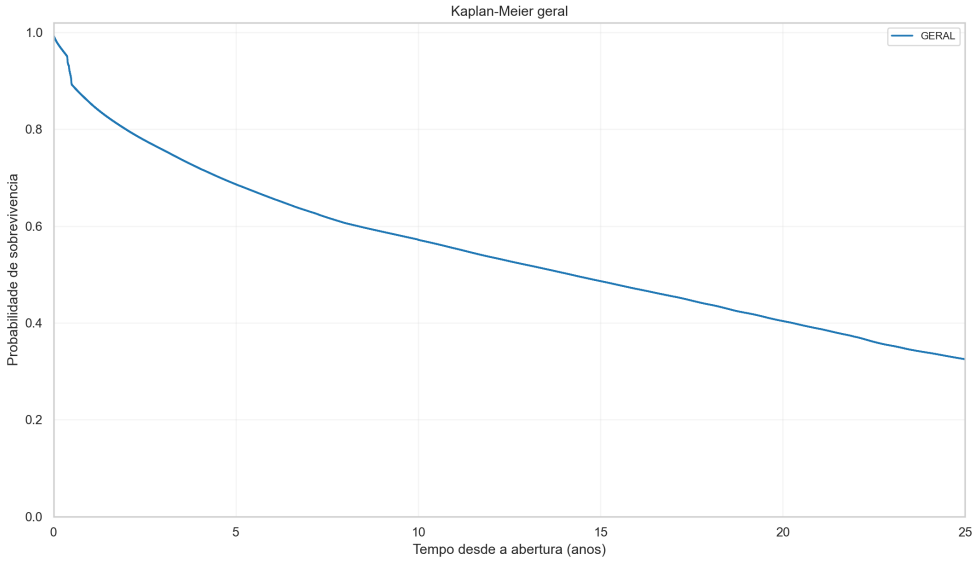

Figura 1: Curva Kaplan–Meier geral.

O padrão é compatível com forte concentração de risco nos primeiros anos, seguida por uma desaceleração gradual. A leitura correta aqui é estrutural e observacional: a base mostra a

duração observada das empresas registradas, não uma dinâmica causal isolada de qualquer composição de coorte.

4.2 Heterogeneidade por coorte e porte

As curvas por coorte mostram que a data de abertura é uma das chaves interpretativas mais fortes do estudo. Empresas abertas entre 1995 e 1999 apresentam sobrevivência estimada de 80,63% em 10 anos, enquanto a coorte 2010–2014 cai para 48,51%. O efeito de composição temporal é suficientemente forte para deslocar toda a leitura da duração empresarial.

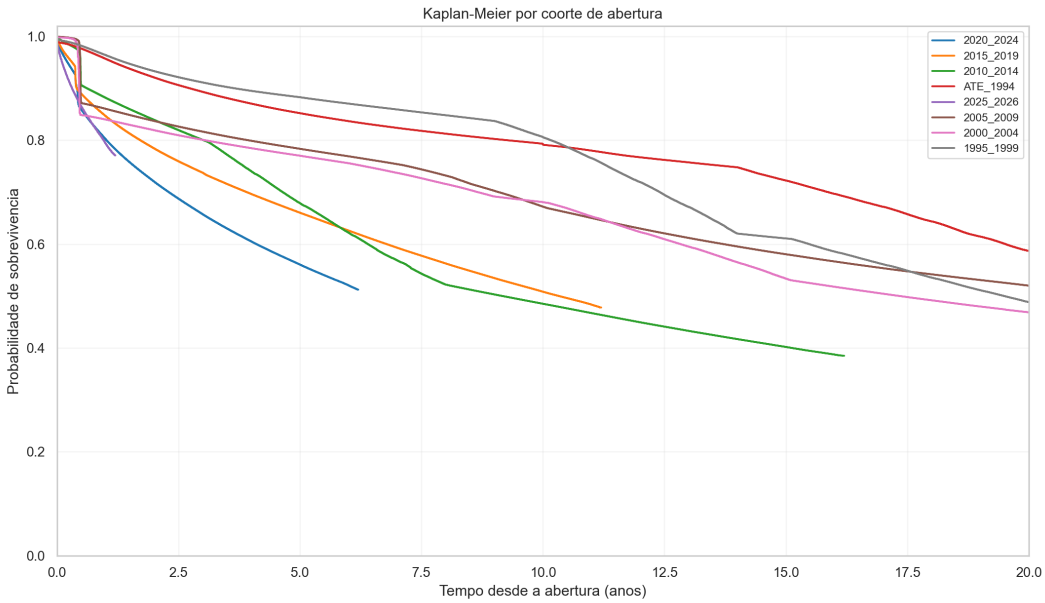

Figura 2: Kaplan–Meier por coorte de abertura.

Por porte observado, a diferença também é expressiva. Empresas de pequeno porte chegam a 81,38% de sobrevivência em 10 anos, enquanto microempresas ficam em 55,45%. Esse resultado não deve ser lido como causalidade simples do porte. Ele mostra que o cadastro, quando particionado por estratos administrativos, revela populações com perfis de duração bastante distintos.

Tabela 2: Exemplos de heterogeneidade em 10 anos

Recorte	Grupo	Sobrevivência em 10 anos
Coorte	1995–1999	80,63%
Coorte	2010–2014	48,51%
Porte	Empresa de pequeno porte	81,38%
Porte	Micro empresa	55,45%

4.3 Motivos de baixa e riscos competitivos

A camada de competing risks mostra que a principal causa administrativa em 10 anos é “extinção por encerramento liquidação voluntária”, com incidência acumulada de 37,66%. As causas seguintes aparecem muito abaixo desse patamar, como “registro cancelado” com 3,00% e “outros motivos” com 0,55%.

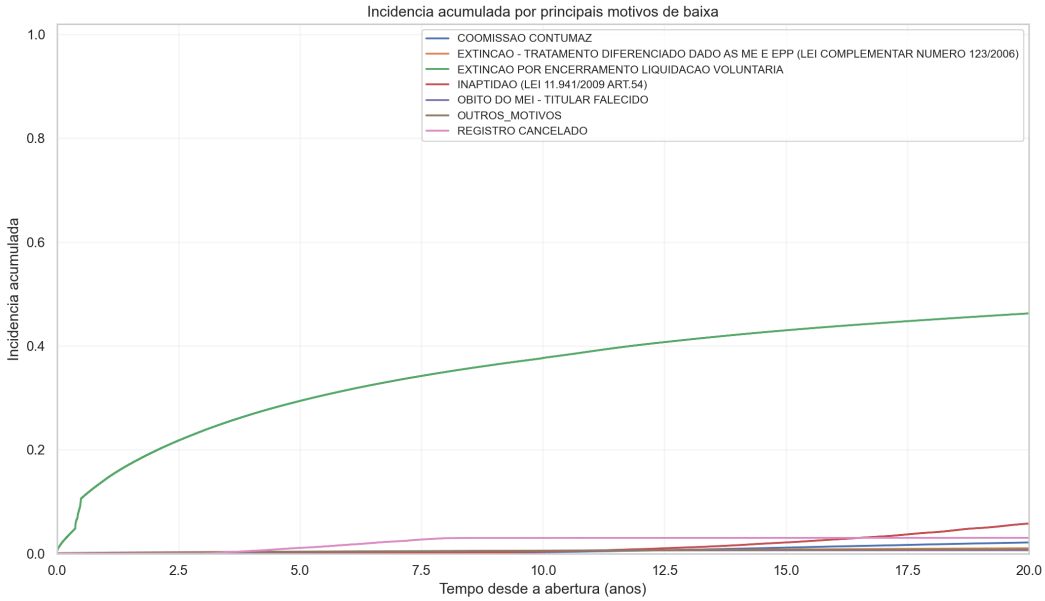

Figura 3: Incidência acumulada por principais motivos de baixa.

Essa decomposição é útil porque evita resumir toda a baixa em um único bloco homogêneo. Ao mesmo tempo, ela continua sendo uma leitura administrativa do cadastro. O significado econômico de cada motivo exige contexto adicional fora da base.

4.4 Radar de risco de baixa em 12 meses

Na validação, modelos como random forest, XGBoost, LightGBM e regressão logística ficaram muito próximos em PR-AUC, todos por volta de 0,126. A escolha final recaiu sobre `logistic_full` porque o empate prático em PR-AUC foi desempatado por melhor qualidade probabilística e simplicidade de implantação.

No teste temporal de 2024, o modelo final obteve:

- ROC-AUC de 0,6975;
- PR-AUC de 0,1327;
- Brier de 0,0594;
- lift de 2,53x no top 10%;
- precisão de 0,168 e recall de 0,247 no limiar de alto risco.

Tabela 3: Métricas do modelo final no teste

Métrica	Valor
ROC-AUC	0,6975
PR-AUC	0,1327
Brier	0,0594
Log-loss	0,2265
Lift top 10%	2,53x
Threshold alto risco	0,1168
Precisão alto risco	0,1676
Recall alto risco	0,2470

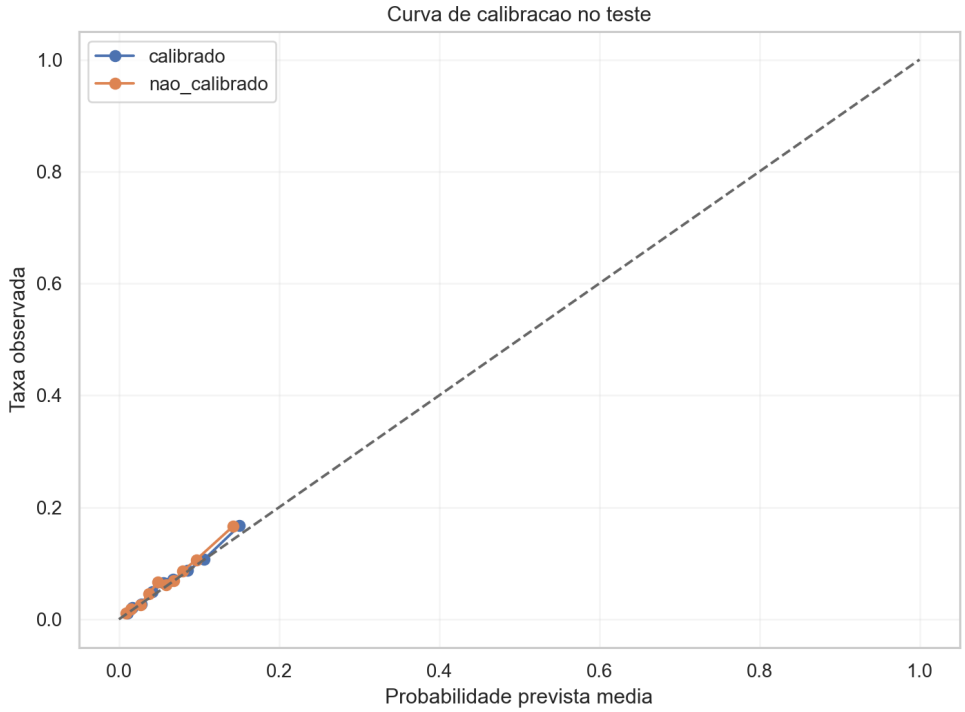

Figura 4: Calibração do score no teste temporal.

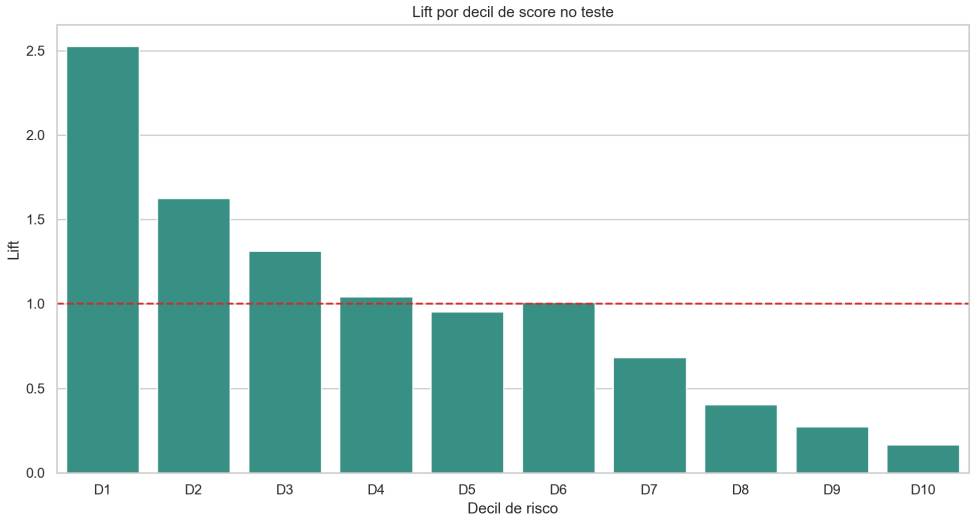

Figura 5: Lift por decil no teste temporal.

A leitura operacional do resultado é mais importante que a métrica isolada. Em um problema desbalanceado com taxa base de 6,57%, concentrar 2,53 vezes a taxa base no decil superior já é um ganho real de priorização.

4.5 Sinais mais fortes do score

Os principais sinais globais do radar final foram idade da empresa, enquadramento no Simples, histórico de exclusão do Simples, adesão ao MEI e coorte de abertura. Em outras palavras, o score aprende majoritariamente com idade e regime cadastral, e não com uma coleção difusa de atributos frágeis.

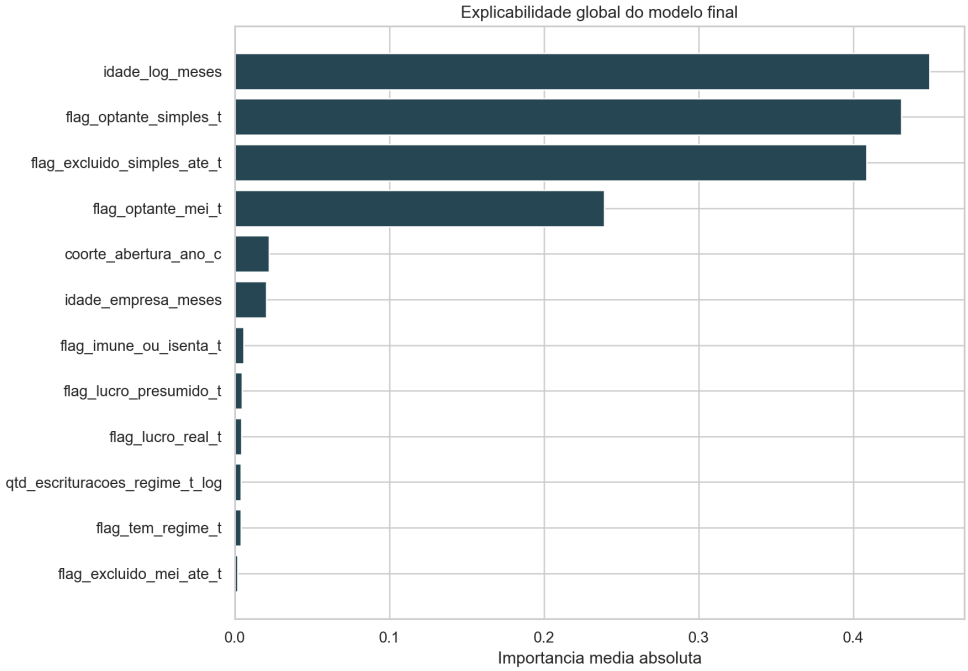

Figura 6: Importância global das variáveis do radar final.

Esse achado reforça a interpretação metodológica do projeto: boa parte do valor do radar vem de preservar coerência temporal e disciplina de feature engineering, não de complexidade algorítmica pela complexidade.

5 Discussão

O trabalho produz dois resultados complementares.

O primeiro é estrutural. A base aberta do CNPJ permite descrever a duração observada das empresas brasileiras em escala nacional, com uma mediana Kaplan–Meier de 14,17 anos e forte heterogeneidade por coorte e porte. A data de abertura se mostrou especialmente importante, o que sugere que qualquer leitura agregada sem recorte temporal perde parte decisiva da história.

O segundo é operacional. É possível construir um radar de baixa em 12 meses metodologicamente defensável sem recorrer a leakage temporal e sem depender de um modelo excessivamente complexo. O score final não deve ser tratado como explicação causal de encerramento empresarial. Ele é um instrumento de priorização probabilística sob restrições reais de dado administrativo.

Há também limites claros. Parte das covariáveis cadastrais é fotografia observada do cadastro, e não histórico longitudinal perfeito. O Cox foi mantido como leitura exploratória. Alguns grupos administrativos especiais exigem interpretação contextual. E, como em qualquer base administrativa massiva, o significado substantivo de um código cadastral nem sempre coincide com o mecanismo econômico subjacente.

6 Conclusão

Este projeto mostra que dados administrativos abertos podem sustentar um estudo robusto de sobrevivência empresarial e um radar de risco de baixa quando o desenho temporal, a auditoria e a comunicação metodológica são tratados como parte central da solução.

Mais do que produzir uma métrica, o trabalho organiza uma trilha completa: base consolidada, inferência temporal, score calibrado, figuras finais e artigo técnico. O valor principal está na combinação entre escala de dado, disciplina metodológica e leitura honesta das limitações.

Referências

Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950. doi: 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

D. R. Cox. Regression models and life-tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 34(2):187–220, 1972.

Jason P. Fine and Robert J. Gray. A proportional hazards model for the subdistribution of a competing risk. *Journal of the American Statistical Association*, 94(446):496–509, 1999. doi: 10.1080/01621459.1999.10474144.

E. L. Kaplan and Paul Meier. Nonparametric estimation from incomplete observations. *Journal of the American Statistical Association*, 53(282):457–481, 1958.

Receita Federal do Brasil. Dados da base CNPJ. https://www.gov.br/receitafederal/pt-br/acesso-a-informacao/convenios-e-transferencias/

compartilhamento-de-bases-de-dados-2013-decreto-no-8-789-2016/leiaute-das-bases/dados-da-base-cnpj, 2018. Accessed: 2026-04-10.